

Hors de la Caverne

Statistique

Des problèmes, pas de réponses. Chaque problème ci-dessous est posé sans solution. Les références indiquent où trouver les connaissances nécessaires.

Lycée

Problème 1 (Moyenne contre médiane — Lycée). **STA-01. Problème.** Pour des réels $x_1, \dots, x_n$, on pose

$$f(c) = \sum_{i=1}^n (x_i - c)^2, \quad g(c) = \sum_{i=1}^n |x_i - c|.$$

- (a) Démontrez que f atteint son minimum en un unique point, la moyenne des nombres.
- (b) Démontrez que g atteint son minimum en toute médiane (tout point ayant au moins la moitié des données de chaque côté), et déterminez exactement quand le minimiseur est unique.
- (c) Construisez une liste de dix « revenus des ménages » dont la moyenne dépasse dix fois la médiane, et argumentez laquelle des deux est le « revenu typique » honnête pour votre liste — avec une raison mathématique, pas un slogan.

La tension entre les deux moyennes est ancienne : la moyenne appartient à la tradition des moindres carrés de Legendre et Gauss, tandis que la médiane fut défendue par Laplace (qui démontra qu'elle minimise l'erreur absolue) puis par Edgeworth. Le choix tranche encore aujourd'hui des débats publics — revenus, prix de l'immobilier, délais d'attente à l'hôpital — parce que la moyenne court après les valeurs extrêmes et la médiane non. La partie (b) est une véritable démonstration sur une fonction affine par morceaux plutôt que dérivable, ce qui est exactement pourquoi elle mérite d'être rédigée.

Références :

- Contexte : Médiane (statistiques) — Wikipédia ([https://fr.wikipedia.org/wiki/M%C3%A9diane_\(statistiques\)](https://fr.wikipedia.org/wiki/M%C3%A9diane_(statistiques)))
- Lecture : D. Freedman, R. Pisani & R. Purves, *Statistics*, ch. 4
- Cours : MIT OCW 18.650 Statistics for Applications (<https://ocw.mit.edu/courses/18-650-statistics-for-applications/>)

Problème 2 (Construisez votre propre paradoxe de Simpson — Lycée). **STA-02. Problème.** Deux hôpitaux, A et B , traitent chacun exactement 1000 patients, chaque patient étant classé comme cas bénin ou cas grave.

- (a) Construisez des données entières telles que : l'hôpital A ait un taux de survie strictement supérieur à celui de B chez les cas bénins, A ait un taux de survie strictement supérieur à celui de B chez les cas graves, et pourtant B ait un taux de survie global strictement supérieur.

- (b) *Démontrez le résultat d'impossibilité suivant : si les deux hôpitaux traitent le même nombre de cas bénins (et donc le même nombre de cas graves), aucune inversion de ce genre ne peut se produire.*

L'inversion porte le nom d'E. H. Simpson (1951), bien que Karl Pearson et Udny Yule l'aient remarquée un demi-siècle plus tôt. Le cas réel le plus célèbre est celui des données d'admission en troisième cycle à Berkeley en 1973, analysées par Bickel, Hammel et O'Connell : l'université semblait globalement défavoriser les femmes, alors que département par département ce n'était pas le cas — les femmes avaient postulé aux départements les plus sélectifs. Le paradoxe est un théorème sur les moyennes pondérées, et votre démonstration d'impossibilité montrera exactement d'où vient la liberté d'inverser.

Références :

- Contexte : Paradoxe de Simpson — Wikipédia (https://fr.wikipedia.org/wiki/Paradoxe_de_Simpson)
- Lecture : J. Pearl & D. Mackenzie, *The Book of Why*, ch. 6
- Article : P. J. Bickel, E. A. Hammel & J. W. O'Connell, « Sex bias in graduate admissions : Data from Berkeley », *Science* 187 (1975), 398–404

Problème 3 (Corrélation n'est pas causalité — sous forme de théorème — Lycée). **STA-03.**

Problème. *La corrélation empirique r de données appariées mesure l'association linéaire et vérifie toujours $-1 \leq r \leq 1$ (vous pouvez l'admettre).*

- (a) *Soient Z, U, V des quantités aléatoires indépendantes, chacune d'espérance 0 et de variance 1, et posons $X = Z + U$ et $Y = Z + V$. Montrez que la corrélation (théorique) de X et Y vaut $1/2$, alors que ni X ni Y n'influence l'autre — ils partagent seulement la cause commune Z .*
- (b) *Construisez une variable aléatoire X prenant un nombre fini de valeurs, telle que X et $Y = X^2$ aient une corrélation exactement nulle bien que Y soit entièrement déterminée par X . Démontrez les deux affirmations.*
- (c) *Concluez, en un paragraphe soigneux, sur ce qu'une corrélation non nulle établit et n'établit pas, et sur ce qu'une corrélation nulle établit et n'établit pas.*

« Corrélation n'implique pas causalité » est d'ordinaire laissé à l'état de proverbe ; il devient ici deux petits théorèmes. La partie (a) est le *facteur de confusion* : les ventes de glaces et les noyades sont corrélées parce que l'été entraîne les deux. La partie (b) montre le piège réciproque : corrélation nulle n'est pas indépendance. Le coefficient de corrélation lui-même est dû à Francis Galton et Karl Pearson dans les années 1880–1890 ; la mathématique moderne des conditions sous lesquelles une corrélation *peut* soutenir une affirmation causale est l'objet de l'inférence causale, l'un des domaines les plus vivants de la statistique d'aujourd'hui.

Références :

- Contexte : Corrélation n'implique pas causalité — Wikipédia (https://fr.wikipedia.org/wiki/Corr%C3%A9lation_n'implique_pas_causalit%C3%A9)
- Contexte : Coefficient de corrélation de Pearson — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Pearson_correlation_coefficient)
- Lecture : D. Freedman, R. Pisani & R. Purves, *Statistics*, ch. 9–12

Problème 4 (Pourquoi les fils des pères grands sont plus petits — Lycée, short). **STA-19. Pro-**

blème. *Soient X et Y les tailles standardisées du père et du fils (chacune d'espérance 0 et d'écart type 1), de corrélation r , et supposons la moyenne conditionnelle linéaire : $\mathbb{E}[Y \mid X = x] = a + bx$.*

Démontrez que $a = 0$ et $b = r$, de sorte que $|\mathbb{E}[Y \mid X = x]| < |x|$ dès que $|r| < 1$ et $x \neq 0$, puis expliquez — par un argument de symétrie, pas par un slogan — pourquoi cela ne signifie pas que la dispersion des tailles se réduit de génération en génération.

Francis Galton découvrit l'effet dans les années 1880 et l'appela « régression vers la médiocrité » ; toute la discipline moderne de l'analyse de régression tire son nom de cette seule observation biologique. Le point de la seconde moitié du problème est que le même argument mené à l'envers prédit que les fils grands avaient des pères plus petits, ce qu'aucune théorie de l'hérédité ne peut expliquer — l'effet est une propriété de la corrélation imparfaite, pas de la biologie. C'est aussi le piège classique de l'évaluation des interventions : les écoles les moins performantes, les patients les plus malades et les pilotes les plus malchanceux s'améliorent tout seuls, et quelque chose d'autre en récolte toujours le crédit.

Références :

- Contexte : Régression vers la moyenne — Wikipédia (https://fr.wikipedia.org/wiki/R%C3%A9gression_vers_la_moyenne)
- Article : F. Galton, « Regression towards mediocrity in hereditary stature », *Journal of the Anthropological Institute* 15 (1886), 246–263
- Lecture : D. Freedman, R. Pisani & R. Purves, *Statistics*, ch. 10

Problème 5 (Une garantie qui n'a besoin d'aucune courbe en cloche — Lycée, short). **STA-20. Problème.** Soit $x_1, \dots, x_n$ une liste quelconque de nombres, de moyenne $\bar{x}$ et d'écart type $s = \sqrt{\frac{1}{n} \sum_i (x_i - \bar{x})^2}$, et soit $k > 1$. Démontrez que la proportion de la liste située à une distance au moins ks de $\bar{x}$ est au plus $1/k^2$, et montrez que la borne ne peut pas être améliorée en exhibant une liste de huit nombres pour laquelle cette proportion vaut exactement $1/4$ lorsque $k = 2$.

C'est l'inégalité de Bienaymé-Tchebychev dépouillée de toute probabilité : la démonstration tient en une ligne d'arithmétique — chaque terme de la somme des carrés est positif, alors jetez les petits. La fameuse règle « 68-95-99,7 » est bien plus fine, mais elle ne vaut que pour la courbe normale ; la borne de Tchebychev vaut pour des données de revenus, des magnitudes de séismes et n'importe quelle liste que vous rencontrerez, ce qui explique que Tchebychev s'en soit servi en 1867 pour démontrer la loi des grands nombres sans rien supposer sur la forme de la loi.

Références :

- Contexte : Inégalité de Bienaymé-Tchebychev — Wikipédia (https://fr.wikipedia.org/wiki/In%C3%A9galit%C3%A9_de_Bienaym%C3%A9-Tchebychev)
- Contexte : Règle 68-95-99,7 — Wikipédia (https://fr.wikipedia.org/wiki/R%C3%A8gle_68-95-99,7)
- Lecture : D. Freedman, R. Pisani & R. Purves, *Statistics*, ch. 4–5

Problème 6 (Compter des poissons que l'on ne peut pas compter — Lycée). **STA-21. Problème.** Un lac contient un nombre inconnu N de poissons. Vous en capturez K , vous les marquez et vous les relâchez ; plus tard vous capturez un second échantillon de n poissons, dont k se révèlent marqués. On suppose que tout sous-ensemble de n poissons a la même probabilité d'être le second échantillon.

- (a) Écrivez la probabilité d'observer exactement k poissons marqués (une probabilité hypergéométrique), en fonction de l'inconnue N .
- (b) En examinant le rapport $L(N)/L(N-1)$ de vraisemblances consécutives, démontrez que cette probabilité est maximale en $\hat{N} = \lfloor Kn/k \rfloor$ lorsque $k \geq 1$ — l'estimateur du maximum de vraisemblance est exactement la règle de proportionnalité naïve $k/n \approx K/N$.

- (c) Montrez que $\hat{N}$ est inutilisable tel quel : $P(k = 0) > 0$ pour tout $N \geq K + n$, et sur cet événement l'estimation est infinie. Démontrez que l'estimateur de Chapman

$$\tilde{N} = \frac{(K+1)(n+1)}{k+1} - 1$$

est exactement sans biais dès que $K + n \geq N$. (Une identité de type Vandermonde pour les coefficients binomiaux fait le travail.)

- (d) Calculez les deux estimations pour $K = 100$, $n = 100$, $k = 20$. Énumérez ensuite les hypothèses de modélisation — population fermée, aucune marque perdue, tous les poissons également capturables — et pour chacune dites dans quel sens son échec ferait dévier l'estimation.

Laplace utilisa la même arithmétique en 1802 pour estimer la population de la France à partir des registres de naissances, et la méthode fut réinventée pour les animaux par C. G. J. Petersen pour les poissons (1896) et F. C. Lincoln pour les oiseaux d'eau bagués (1930) ; la correction de biais de (c) est celle de D. G. Chapman, en 1951. La technique sert aujourd'hui bien au-delà de l'écologie : estimer le sous-dénombrement d'un recensement, le nombre de défauts logiciels non découverts et — en croisant plusieurs listes incomplètes — le nombre de victimes d'un conflit armé. C'est l'exemple le plus net, en statistique élémentaire, de la façon d'apprendre la taille d'une chose que l'on ne pourra jamais voir en entier.

Références :

- Contexte : Capture-marquage-recapture — Wikipédia (<https://fr.wikipedia.org/wiki/Capture-marquage-recapture>)
- Contexte : Loi hypergéométrique — Wikipédia (https://fr.wikipedia.org/wiki/Loi_hypergéométrique)
- Lecture : G. A. F. Seber, *The Estimation of Animal Abundance and Related Parameters*, 2e éd.

Problème 7 (La dame qui déguste du thé — Lycée, short). **STA-31. Problème.** On prépare huit tasses de thé, quatre où le lait a été versé en premier et quatre où c'est le thé ; on informe la dégustatrice qu'il y en a quatre de chaque sorte et elle doit désigner les quatre tasses au lait versé en premier, de sorte que sous l'hypothèse nulle où elle devine au hasard, les $\binom{8}{4} = 70$ sélections possibles sont équiprobables. Démontrez que la probabilité de désigner les quatre correctement par hasard vaut $1/70$, calculez la probabilité d'en trouver au moins trois sur quatre, et déduisez-en qu'au seuil de 5 % rien de moins qu'un sans-faute ne peut compter comme preuve — puis dites ce qui change si l'expérience est menée avec six tasses, trois de chaque sorte.

Ronald Fisher ouvre *The Design of Experiments* (1935) par cette expérience, et elle a réellement eu lieu : à Rothamsted, dans les années 1920, l'algologue Muriel Bristol affirmait pouvoir sentir au goût si le lait avait été versé dans la tasse en premier, et Fisher conçut le test sur-le-champ. Ce chapitre est le premier endroit où la randomisation, l'hypothèse nulle et la valeur p exacte apparaissent ensemble, et le dénombrement que vous venez de faire est le *test exact de Fisher* pour un tableau 2×2 — pas d'approximation normale, pas de théorie asymptotique, rien que de la combinatoire. Remarquez ce que révèle la dernière partie : le plus petit effet détectable est fixé par le plan d'expérience avant qu'une seule tasse ne soit versée, et c'est pourquoi Fisher insistait pour que l'on consulte le statisticien avant l'expérience plutôt qu'après.

Références :

- Contexte : La dame dégustant du thé — Wikipédia (https://fr.wikipedia.org/wiki/The_lady_tasting_tea)
- Contexte : Test exact de Fisher — Wikipédia (https://fr.wikipedia.org/wiki/Test_exact_de_Fisher)

- Lecture : R. A. Fisher, *The Design of Experiments* (1935), ch. 2
- Lecture : D. Salsburg, *The Lady Tasting Tea : How Statistics Revolutionized Science in the Twentieth Century* (2001)

Problème 8 (Deux millions de mauvaises réponses — Lycée). **STA-32. Problème.** Une population comporte une fraction p d'électeurs favorables au candidat R et $1 - p$ favorables au candidat L . Un magazine envoie des bulletins par la poste à une immense liste de noms. Indépendamment de tout le reste, un électeur favorable à R renvoie le bulletin avec probabilité r_1 , et un électeur favorable à L le renvoie avec probabilité r_0 ; le magazine publie la fraction de partisans de R parmi les bulletins qui lui reviennent.

- (a) Démontrez que lorsque le nombre de bulletins envoyés croît, la fraction publiée se stabilise non pas en p mais en

$$p^* = \frac{p r_1}{p r_1 + (1 - p) r_0},$$

et que $p^* = p$ si et seulement si $r_1 = r_0$. Remarquez que le nombre de bulletins n'apparaît nulle part dans p^* : l'erreur ne diminue pas quand le sondage grossit.

- (b) Injectez les chiffres historiques. En 1936, le *Literary Digest* envoya environ dix millions de bulletins, en reçut environ 2,38 millions en retour, et prédit que Landon obtiendrait 57 % des voix ; Roosevelt en obtint 60,8 %. À l'aide de (a), déterminez le rapport r_1/r_0 des taux de réponse qui expliquerait à lui seul l'écart, et commentez la modestie de ce différentiel.
- (c) Montrez que l'erreur d'échantillonnage n'était pas le problème. Pour un échantillon réellement aléatoire de taille n tiré de la population, démontrez que l'écart type de la fraction observée vaut $\sqrt{p(1-p)/n} \leq 1/(2\sqrt{n})$, et évaluez-le pour $n = 2380000$. Comparez le résultat à l'erreur de 20 points du magazine, puis trouvez la taille d'échantillon à laquelle la seule erreur d'échantillonnage aléatoire atteint un point de pourcentage.
- (d) Le *Digest* a commis deux erreurs distinctes : il a bâti son fichier d'adresses à partir d'annuaires téléphoniques, de listes de clubs et d'immatriculations d'automobiles, et il a accepté la réponse de quiconque voulait bien répondre. Expliquez, à l'aide de (a), pourquoi chacune est fatale à elle seule, et démontrez qu'envoyer vingt millions de bulletins au lieu de dix n'aurait remédié ni à l'une ni à l'autre.

Le *Literary Digest* avait correctement annoncé toutes les élections présidentielles depuis 1920 et était si confiant dans le volume brut qu'il publia sa prévision de 1936 comme une quasi-certitude ; George Gallup, travaillant sur un échantillon d'environ cinquante mille personnes choisies pour représenter l'électorat, annonça le résultat correct, et le magazine disparut en moins de deux ans. La reconstitution de Peverill Squire en 1988 a identifié la non-réponse comme le plus grave des deux échecs : les partisans de Roosevelt renvoyaient tout simplement moins de bulletins. La leçon n'est pas seulement historique. Xiao-Li Meng a montré en 2018 que l'erreur d'une moyenne d'échantillon se factorise en un terme de qualité des données, un terme de quantité de données et la variance de la population, de sorte qu'une corrélation minuscule entre le fait de répondre et la préférence rend un échantillon énorme aussi mauvais qu'un petit échantillon aléatoire — son « paradoxe des mégadonnées », appliqué à l'élection américaine de 2016, est STA-32(a) réécrit pour le XXI^e siècle.

Références :

- Contexte : The Literary Digest — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/The_Literary_Digest)
- Contexte : Échantillon biaisé — Wikipédia (https://fr.wikipedia.org/wiki/%C3%89chantillon_biais%C3%A9)

- Article : P. Squire, « Why the 1936 Literary Digest poll failed », *Public Opinion Quarterly* 52 (1988), 125–133
- Article : X.-L. Meng, « Statistical paradises and paradoxes in big data (I) », *Annals of Applied Statistics* 12 (2018), 685–726

Licence

Problème 9 (Les moindres carrés et les équations normales — Licence). **STA-04. Problème.** Étant donné des points $(x_1, y_1), \dots, (x_n, y_n)$ dont les x_i ne sont pas tous égaux, on ajuste une droite $y = a + bx$ en minimisant

$$S(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2.$$

- Établissez les équations normales en annulant les deux dérivées partielles $\partial S / \partial a$ et $\partial S / \partial b$, résolvez-les, et démontrez que le point critique est l'unique minimum global.
- Montrez que la droite ajustée passe toujours par le point moyen $(\bar{x}, \bar{y})$.
- Sous forme matricielle, X désignant la matrice de plan $n \times p$ de rang maximal en colonnes, montrez que minimiser $\|y - X\beta\|^2$ conduit aux équations normales $X^\top X\beta = X^\top y$. Interprétez la solution géométriquement — le vecteur ajusté $X\hat{\beta}$ est la projection orthogonale de y sur l'espace des colonnes de X — et démontrez cette interprétation.

Les moindres carrés sont l'algorithme fondateur de la statistique. Legendre les publia en 1805 dans un appendice sur les orbites cométaires ; Gauss affirma les employer depuis 1795 et les relia en 1809 à la loi normale — la querelle de priorité fut âpre. Le premier triomphe de la méthode fut de retrouver l'astéroïde Cérès perdu à partir d'une poignée d'observations. Les équations normales que vous établissez ici sont résolues des millions de fois par seconde au cur de tous les systèmes de régression, de prévision et d'apprentissage automatique qui existent.

Références :

- Contexte : Méthode des moindres carrés — Wikipédia (https://fr.wikipedia.org/wiki/M%C3%A9thode_des_moindres_carr%C3%A9s)
- Lecture : G. Casella & R. L. Berger, *Statistical Inference*, 2e éd., ch. 11–12
- Cours : MIT OCW 18.650 Statistics for Applications (<https://ocw.mit.edu/courses/18-650-statistics-for-applications/>)

Problème 10 (Le maximum de vraisemblance, quatre fois — Licence). **STA-05. Problème.** Des observations indépendantes $x_1, \dots, x_n$ sont tirées de chacun des modèles ci-dessous. Pour chacun des cas (a)–(d), écrivez la vraisemblance, établissez l'estimateur du maximum de vraisemblance (EMV), et vérifiez que c'est bien un maximum.

- Bernoulli de probabilité de succès p .
- Poisson d'espérance λ .
- Exponentielle de taux λ .
- Normale $N(\mu, \sigma^2)$ avec les deux paramètres inconnus.
- Déterminez, pour chaque estimateur trouvé, s'il est sans biais ; là où il est biaisé, calculez le biais exactement.
- Démontrez la propriété d'invariance : si $\hat{\theta}$ est un EMV de θ et si g est une bijection, alors $g(\hat{\theta})$ est un EMV de $g(\theta)$.

Le maximum de vraisemblance est la création de R. A. Fisher — esquissé dans un article d'étudiant de 1912 et développé dans son grand mémoire de 1922, qui introduisit aussi les mots « paramètre », « statistique », « exhaustivité » et « efficacité » dans leur sens moderne. Le principe — rendre les données aussi probables que possible — a l'air d'une heuristique, et pourtant il produit des estimateurs asymptotiquement optimaux sous des conditions très générales (voir STA-14). La partie (e) réserve une petite surprise : l'un des estimateurs les plus naturels de la statistique est biaisé, ce qui mène directement au problème suivant.

Références :

- Contexte : Maximum de vraisemblance — Wikipédia (https://fr.wikipedia.org/wiki/Maximum_de_vraisemblance)
- Lecture : G. Casella & R. L. Berger, *Statistical Inference*, 2e éd., ch. 7
- Article : R. A. Fisher, « On the mathematical foundations of theoretical statistics », *Philosophical Transactions of the Royal Society A* 222 (1922), 309–368

Problème 11 (Pourquoi diviser par $n - 1$? — Licence). **STA-06. Problème.** Soient $x_1, \dots, x_n$ des tirages indépendants d'une loi quelconque d'espérance μ et de variance finie σ^2 , et soit $\bar{x}$ la moyenne empirique. On définit la variance empirique

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

(a) Démontrez l'identité

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \mu)^2 - n(\bar{x} - \mu)^2,$$

et servez-vous-en pour démontrer $\mathbb{E}[S^2] = \sigma^2$.

- (b) Montrez que diviser par n donne au contraire l'espérance $\sigma^2(n-1)/n$, de sorte que l'estimateur « naturel » sous-estime systématiquement la variance. Expliquez avec vos mots pourquoi mesurer la dispersion autour de $\bar{x}$ plutôt qu'autour de μ fait perdre exactement l'information d'une observation.
- (c) Montrez que l'absence de biais ne survit pas à la racine carrée : S n'est pas un estimateur sans biais de σ (supposez que la loi n'est pas concentrée en un point).

Le $n - 1$ s'appelle la correction de Bessel, d'après l'astronome Friedrich Bessel, et c'est la première rencontre honnête de la plupart des étudiants avec la notion de biais. L'idée plus profonde — que les résidus $x_i - \bar{x}$ vivent dans un espace de dimension $(n - 1)$, à l'origine de l'expression « degrés de liberté » — fut rendue précise par Fisher dans les années 1920. La partie (c) est un avertissement utile : l'absence de biais est une propriété d'un paramétrage donné, pas une loi de la nature.

Références :

- Contexte : Correction de Bessel — Wikipédia (https://fr.wikipedia.org/wiki/Correction_de_Bessel)
- Lecture : G. Casella & R. L. Berger, *Statistical Inference*, 2e éd., ch. 5

Problème 12 (Ce que promet un intervalle de confiance — Licence). **STA-07. Problème.** Soient $x_1, \dots, x_n$ des observations indépendantes $N(\mu, \sigma^2)$ avec σ connu.

- (a) Démontrez l'énoncé de couverture : l'intervalle aléatoire $\bar{x} \pm 1,96 \sigma / \sqrt{n}$ contient μ avec probabilité 0,95 — la probabilité portant sur le tirage des données, avant que celles-ci ne soient vues, et cela quelle que soit la vraie valeur de μ .

- (b) Expliquez précisément pourquoi la phrase « ayant calculé l'intervalle $[2,1; 3,4]$, le paramètre μ s'y trouve avec probabilité 95 % » n'est pas autorisée par (a), et quelle est la bonne interprétation fréquentiste sur des expériences répétées.
- (c) Voici maintenant l'exemple d'école qui met en garde. Un paramètre θ est inconnu ; deux observations indépendantes X_1, X_2 valent chacune $\theta - 1$ ou $\theta + 1$, chacune avec probabilité $1/2$. On définit l'ensemble de confiance C : si $X_1 \neq X_2$, on pose $C = \{(X_1 + X_2)/2\}$; si $X_1 = X_2$, on pose $C = \{X_1 - 1\}$. Démontrez que C couvre θ avec probabilité exactement 75 %, et pourtant qu'après avoir vu les données vous êtes soit logiquement certain que $C = \{\theta\}$, soit assuré que la couverture n'est qu'un coup de pile ou face. Que dit cela sur le fait d'attacher le niveau de confiance pré-expérimental à un intervalle particulier une fois réalisé ?

Les intervalles de confiance ont été introduits par Jerzy Neyman dans un article de 1937 qui mérite encore d'être lu pour sa rigueur philosophique : le niveau de confiance décrit la performance à long terme de la *procédure*, pas la probabilité d'un intervalle réalisé particulier. L'exemple (c) — un exemple d'enseignement classique, discuté par Berger, Wolpert, Wasserman et d'autres — montre que les deux choses peuvent diverger spectaculairement. Les énoncés sur la probabilité d'un paramètre sachant les données relèvent de l'inférence bayésienne (STA-10), qui fait d'autres hypothèses pour se les autoriser.

Références :

- Contexte : Intervalle de confiance — Wikipédia (https://fr.wikipedia.org/wiki/Intervalle_de_confiance)
- Lecture : L. Wasserman, *All of Statistics*, ch. 6
- Article : J. Neyman, « Outline of a theory of statistical estimation based on the classical theory of probability », *Philosophical Transactions of the Royal Society A* 236 (1937), 333–380

Problème 13 (La logique des valeurs p — Licence). **STA-08. Problème.** Soit T une statistique de test de loi continue sous l'hypothèse nulle H_0 , les grandes valeurs comptant contre H_0 , et soit la valeur p $p = P_0(T \geq t_{\text{obs}})$.

- (a) Démontrez que sous H_0 la valeur p suit la loi uniforme sur $(0, 1)$, et déduisez-en que la règle « rejeter lorsque $p \leq \alpha$ » a une probabilité d'erreur de première espèce exactement égale à α .
- (b) Expliquez soigneusement pourquoi p n'est pas la probabilité que H_0 soit vraie, et pourquoi $1 - p$ n'est pas la probabilité que l'alternative soit vraie.
- (c) Construisez un exemple explicite où la preuve empirique paraît accablante et où pourtant l'hypothèse nulle survit à un audit bayésien : $H_0: \theta = 0$ contre $H_1: \theta \neq 0$ pour l'espérance de données $N(\theta, 1)$, avec une probabilité a priori $1/2$ sur H_0 et, sous H_1 , une loi a priori normale sur θ . Montrez que pour n grand on peut avoir $p = 0,05$ alors que la probabilité a posteriori de H_0 dépasse $1/2$. (C'est le paradoxe de Lindley ; le problème consiste à le poser précisément.)

Les tests de significativité descendent de Fisher, qui voyait la valeur p comme une mesure grossière de la surprise, et de Neyman et Pearson, qui ont refondu le test en une décision à taux d'erreur contrôlés ; le rituel moderne du $p \leq 0,05$ est une fusion inconfortable des deux qu'aucun n'approuverait. Les mauvaises lectures de (b) sont si répandues que l'American Statistical Association a publié une déclaration officielle à leur sujet en 2016. Le paradoxe de Lindley (c), publié en 1957, montre que « significatif à 5 % » et « probablement vrai » peuvent pointer dans des directions opposées.

Références :

- Contexte : Valeur p — Wikipédia (https://fr.wikipedia.org/wiki/Valeur_p)
- Contexte : Paradoxe de Lindley — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Lindley%27s_paradox)
- Lecture : L. Wasserman, *All of Statistics*, ch. 10
- Article : R. L. Wasserstein & N. A. Lazar, « The ASA's statement on p-values », *The American Statistician* 70 (2016), 129–133

Problème 14 (Le lemme de Neyman-Pearson — Licence). **STA-09. Problème.** On teste une hypothèse nulle simple H_0 : les données ont pour densité f_0 , contre une alternative simple H_1 : densité f_1 .

- Démontrez le lemme de Neyman-Pearson : parmi tous les tests de risque de première espèce au plus α , un test qui rejette exactement lorsque $f_1(x)/f_0(x) > k$ (avec k choisi pour que le niveau soit α , en randomisant à la frontière si nécessaire) maximise la puissance $P_1(\text{rejet})$.
- Appliquez-le : pour n observations indépendantes $N(\theta, 1)$, en testant $\theta = 0$ contre $\theta = \theta_1$ avec $\theta_1 > 0$ fixé, montrez que le test du rapport de vraisemblance est précisément le test z unilatéral « rejeter lorsque $\sqrt{n}\bar{x} > z_\alpha$ », et observez que le même test est le plus puissant pour tout $\theta_1 > 0$ simultanément (un test uniformément le plus puissant).

L'article de 1933 de Neyman et Pearson a transformé le test d'hypothèse d'un ensemble d'habitudes en un problème d'optimisation : fixez l'erreur que vous redoutez le plus, puis minimisez l'autre. Le lemme est le théorème fondamental de ce point de vue, et sa démonstration tient en deux lignes d'idée enveloppées de comptabilité — le rapport de vraisemblance ordonne les points de l'échantillon selon leur rendement probant. Tout, de la théorie de la détection radar à la conception des essais cliniques, repose dessus.

Références :

- Contexte : Lemme de Neyman-Pearson — Wikipédia (https://fr.wikipedia.org/wiki/Lemme_de_Neyman-Pearson)
- Lecture : E. L. Lehmann & J. P. Romano, *Testing Statistical Hypotheses*, ch. 3
- Article : J. Neyman & E. S. Pearson, « On the problem of the most efficient tests of statistical hypotheses », *Philosophical Transactions of the Royal Society A* 231 (1933), 289–337

Problème 15 (Lois a priori conjuguées et mise à jour bayésienne — Licence). **STA-10. Problème.**

- Supposons que la probabilité de succès p d'une pièce ait une loi a priori $\text{Beta}(a, b)$ et que l'on observe n lancers indépendants comportant s succès. Établissez la loi a posteriori et montrez qu'il s'agit de $\text{Beta}(a + s, b + n - s)$.
- Montrez que l'espérance a posteriori est une moyenne pondérée de l'espérance a priori $a/(a + b)$ et de la proportion observée s/n , et identifiez les poids ; interprétez $a + b$ comme une « taille d'échantillon a priori ».
- Établissez les couples conjugués analogues : loi a priori gamma avec des données de Poisson, et loi a priori normale avec des données normales de variance connue.
- Démontrez que la mise à jour bayésienne est cohérente : mettre à jour d'un coup sur tout le jeu de données donne la même loi a posteriori que mettre à jour séquentiellement, une observation à la fois.

Le calcul bêta-Bernoulli est essentiellement celui de l'essai posthume de Thomas Bayes de 1763, et Laplace utilisa la même machinerie pour estimer la probabilité du lever du soleil et la masse de

Saturne. L'expression « loi a priori conjuguée » vient de Raiffa et Schlaifer (1961). La conjugaison est ce qui a rendu l'inférence bayésienne calculable pendant deux siècles, avant les méthodes de Monte-Carlo par chaînes de Markov ; la partie (d) est l'expression mathématique de la promesse bayésienne selon laquelle l'ordre dans lequel vous apprenez des faits ne peut pas compter.

Références :

- Contexte : Loi a priori conjuguée — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Conjugate_prior)
- Lecture : A. Gelman et al., *Bayesian Data Analysis*, 3e éd., ch. 2
- Lecture : L. Wasserman, *All of Statistics*, ch. 11

Problème 16 (Le problème du char d'assaut allemand — Licence). **STA-11. Problème.** Les numéros de série $1, 2, \dots, N$ sont estampillés sur N chars ; vous en capturez k , tirés sans remise, tous les sous-ensembles étant équiprobables, et vous observez des numéros de série de maximum M .

- (a) Calculez la loi de M et montrez que l'estimateur du maximum de vraisemblance de N est M lui-même — et qu'il est biaisé par défaut, toujours.
- (b) Démontrez que $\hat{N} = M \left(1 + \frac{1}{k}\right) - 1$ est un estimateur sans biais de N (« ajoutez l'écart moyen »).
- (c) Comparez $\hat{N}$ à l'estimateur des moments $2\bar{x} - 1$ construit sur la moyenne empirique : calculez les deux variances (ou argumentez laquelle est la plus petite), et expliquez pourquoi le maximum est ici un meilleur résumé de l'échantillon que la moyenne.

Pendant la Seconde Guerre mondiale, les statisticiens alliés estimèrent la production allemande de chars à partir des numéros de série des chars capturés et détruits. Leur estimation pour la période juin 1940 – septembre 1942 tournait autour de 246 chars par mois, tandis que le renseignement classique annonçait environ 1400 ; les registres de production capturés montrèrent ensuite un chiffre d'environ 245. L'épisode, documenté par Ruggles et Brodie en 1947, est la démonstration la plus nette qui soit qu'un bon estimateur bat un grand réseau d'espionnage. Le problème est aussi un superbe pendant en population finie de l'estimation de la borne d'une loi uniforme.

Références :

- Contexte : Problème du char d'assaut allemand — Wikipédia (https://fr.wikipedia.org/wiki/Probl%C3%A8me_du_char_d'assaut_allemand)
- Article : R. Ruggles & H. Brodie, « An empirical approach to economic intelligence in World War II », *Journal of the American Statistical Association* 42 (1947), 72–91
- Cours : MIT OCW 18.650 Statistics for Applications (<https://ocw.mit.edu/courses/18-650-statistics-for-app>)

Problème 17 (Égaliser les moments — Licence, short). **STA-22. Problème.** Soient $x_1, \dots, x_n$ des tirages indépendants dans la famille gamma de densité $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$ sur $x > 0$, d'espérance α/β et de variance α/β^2 . Établissez les estimateurs des moments de α et β en égalant les deux premiers moments empiriques à leurs valeurs théoriques, et démontrez que les deux estimateurs convergent en probabilité vers les vrais paramètres, en nommant les deux théorèmes que vous utilisez.

Karl Pearson introduisit la méthode dans son mémoire de 1894 sur l'évolution, où il ajustait un mélange de deux lois normales à des mesures de crabes de Naples et dut résoudre une équation de degré neuf à la main ; ce fut la première procédure d'estimation à usage général de la statistique. Fisher montra plus tard que le maximum de vraisemblance (STA-05) est asymptotiquement plus efficace, et le répéta souvent sans ménagement — mais les estimateurs des moments survivent parce qu'ils n'exigent aucune vraisemblance, fournissent d'excellents points de départ pour une

maximisation numérique et, sous la forme généralisée due à Hansen (1982), sont l'outil standard de l'économétrie.

Références :

- Contexte : Méthode des moments (statistiques) — Wikipédia ([https://fr.wikipedia.org/wiki/M%C3%A9thode_des_moments_\(statistiques\)](https://fr.wikipedia.org/wiki/M%C3%A9thode_des_moments_(statistiques)))
- Article : K. Pearson, « Contributions to the mathematical theory of evolution », *Philosophical Transactions of the Royal Society A* 185 (1894), 71–110
- Lecture : G. Casella & R. L. Berger, *Statistical Inference*, 2e éd., ch. 7

Problème 18 (Le coût des questions multiples — Licence, short). **STA-23. Problème.** Vous testez m hypothèses nulles et rejetez H_i dès que sa valeur p vérifie $p_i \leq \alpha/m$. Démontrez que le taux d'erreur par famille — la probabilité d'au moins un rejet à tort — est au plus α quelle que soit la dépendance entre les tests, et démontrez que lorsque les m hypothèses nulles sont toutes vraies et que les valeurs p sont indépendantes et uniformes, ce taux vaut exactement $1 - (1 - \alpha/m)^m$; quantifiez de combien cela reste en dessous de α pour m grand.

Toute la démonstration se réduit à l'inégalité de Boole, ce qui explique que la correction soit indépassable sans hypothèses supplémentaires et, en même temps, bien trop prudente lorsque les tests sont positivement liés. Elle porte le nom de Carlo Emilio Bonferroni pour ses inégalités de 1936, mais son usage en comparaisons multiples est dû à Olive Jean Dunn (1961), qui en mérite davantage le crédit. Les études d'association pangénomique testent environ un million de marqueurs et déclarent donc la significativité à 5×10^{-8} ; le fait que ce seuil écarte de vraies découvertes est ce qui a motivé le taux de fausses découvertes de STA-17(b).

Références :

- Contexte : Correction de Bonferroni — Wikipédia (https://fr.wikipedia.org/wiki/Correction_de_Bonferroni)
- Contexte : Taux d'erreur par famille — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Family-wise_error_rate)
- Article : O. J. Dunn, « Multiple comparisons among means », *Journal of the American Statistical Association* 56 (1961), 52–64

Problème 19 (La pente est-elle réelle? — Licence). **STA-24. Problème.** Prenez le modèle de régression simple normal : les x_i sont fixés et non tous égaux, et

$$y_i = a + bx_i + \varepsilon_i, \quad \varepsilon_1, \dots, \varepsilon_n \text{ indépendants } N(0, \sigma^2), \quad n \geq 3.$$

Notons $S_{xx} = \sum_i (x_i - \bar{x})^2$, soient $\hat{a}$ et $\hat{b}$ l'ordonnée à l'origine et la pente des moindres carrés de STA-04, et soit $\text{RSS} = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2$.

- (a) Démontrez que $\hat{b}$ est une fonction linéaire des y_i , donc de loi normale, avec $\mathbb{E}[\hat{b}] = b$ et $\text{Var}(\hat{b}) = \sigma^2/S_{xx}$.
- (b) Démontrez que RSS/σ^2 suit la loi du khi-deux à $n - 2$ degrés de liberté et est indépendante de $\hat{b}$. (Décomposez $\mathbb{R}^n$ en l'espace des colonnes de dimension deux de la matrice de plan et son orthogonal, et utilisez l'invariance par rotation de la loi normale multivariée — cette indépendance est un miracle purement gaussien, et c'est le cur du problème.)
- (c) Déduisez-en qu'avec $\hat{\sigma}^2 = \text{RSS}/(n - 2)$,

$$T = \frac{\hat{b} - b}{\hat{\sigma}/\sqrt{S_{xx}}}$$

suit la loi de Student à $n - 2$ degrés de liberté, et écrivez le test de niveau α de $H_0 : b = 0$ qui en résulte ainsi que l'intervalle de confiance à 95% pour b .

- (d) Démontrez que la valeur observée de T sous $H_0 : b = 0$ vaut $r\sqrt{n-2}/\sqrt{1-r^2}$, où r est la corrélation empirique des x et des y . Expliquez ensuite, en un paragraphe soigneux et avec STA-03 en tête, ce que le rejet de H_0 vous autorise exactement à dire.

William Sealy Gosset, brasseur chez Guinness travaillant sur des échantillons de quatre ou cinq, trouva en 1908 la loi qui permet d'utiliser un écart type estimé à la place d'un écart type connu ; Guinness interdisant à ses employés de publier, il signa « Student ». Fisher fournit la géométrie rigoureuse en dimension n — la décomposition orthogonale de la partie (b) — et l'étendit à la régression, où elle est devenue l'énoncé inférentiel le plus utilisé de toute la science : presque toute affirmation publiée de la forme « l'effet était significatif ($p < 0,05$) » est le calcul que l'on vous demande ici de justifier. La partie (d) rappelle que la mathématique certifie une pente, pas une cause.

Références :

- Contexte : Loi de Student — Wikipédia (https://fr.wikipedia.org/wiki/Loi_de_Student)
- Contexte : Régression linéaire simple — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Simple_linear_regression)
- Article : Student (W. S. Gosset), « The probable error of a mean », *Biometrika* 6 (1908), 1–25
- Lecture : G. Casella & R. L. Berger, *Statistical Inference*, 2e éd., ch. 11

Problème 20 (Une seule table pour toutes les lois — Licence, short). **STA-33. Problème.** Soient $X_1, \dots, X_n$ indépendantes de fonction de répartition continue F , soit $\hat{F}_n(x) = \frac{1}{n} \# \{i : X_i \leq x\}$ la fonction de répartition empirique, et soit $D_n = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)|$. Démontrez que les variables $U_i = F(X_i)$ sont indépendantes et uniformes sur $(0, 1)$, déduisez-en que la loi de D_n est la même pour toute F continue, et montrez sur un exemple que la conclusion tombe en défaut lorsque F a un atome.

C'est pour cela que le test de Kolmogorov-Smirnov a pu exister dès 1933 : une seule table de valeurs critiques, calculée une fois pour toutes, sert pour toute hypothèse nulle continue, parce que la transformation intégrale de probabilité efface tout ce qui concerne F hormis sa continuité. Kolmogorov trouva cette année-là la loi limite de $\sqrt{n} D_n$ et Smirnov la version à deux échantillons en 1939 ; Doob expliqua en 1949 que la limite est en réalité une fonctionnelle du pont brownien, ce que Donsker rendit rigoureux en 1952 — le processus empirique, l'un des piliers de la statistique non paramétrique moderne. Le pendant à échantillon fini est l'inégalité de Dvoretzky-Kiefer-Wolfowitz (1956), dont la constante optimale fut fournie par Massart en 1990, et qui transforme D_n en une bande de confiance honnête pour une fonction de répartition inconnue.

Références :

- Contexte : Test de Kolmogorov-Smirnov — Wikipédia (https://fr.wikipedia.org/wiki/Test_de_Kolmogorov-Smirnov)
- Contexte : Transformation intégrale de probabilité — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Probability_integral_transform)
- Lecture : A. W. van der Vaart, *Asymptotic Statistics*, ch. 19

Problème 21 (Les colliders : la corrélation que l'ajustement fabrique — Licence). **STA-34. Problème.** Un collider est une variable influencée par deux autres. Conditionner par un collider est l'image en miroir du conditionnement par un facteur de confusion (STA-03) : au lieu de supprimer une association fallacieuse, il en fabrique une.

- (a) La version de Berkson. Soient A et B deux événements indépendants avec $0 < P(A), P(B) < 1$ — deux maladies sans lien — et soit $H = A \cup B$ l'événement « la personne est hospitalisée », qui se produit si l'une ou l'autre maladie est présente. Démontrez que

$$P(A \mid B \cap H) < P(A \mid H),$$

de sorte qu'à l'intérieur de l'hôpital les deux maladies paraissent négativement associées alors que dans la population elles sont indépendantes.

- (b) *La version gaussienne.* Soient X et Y des variables normales standard indépendantes et soit $Z = X + Y + \varepsilon$ avec $\varepsilon \sim N(0, \sigma^2)$ indépendante des deux. Démontrez que la corrélation partielle de X et Y sachant Z vaut

$$\rho_{XY \cdot Z} = -\frac{1}{1 + \sigma^2},$$

de sorte que « contrôler par Z » produit une forte association négative entre deux variables qui sont exactement indépendantes.

- (c) *La version régression.* Dans le modèle de (b), démontrez que le coefficient théorique des moindres carrés porté par Y dans la régression de X sur (Y, Z) est non nul, alors que le coefficient porté par Y dans la régression de X sur Y seul est nul. Comparez avec le modèle de confusion $X = Z + U$, $Y = Z + V$ de STA-03(a), où ajouter Z à la régression est exactement ce qu'il faut faire, et énoncez la règle générale sur les variables que l'on peut légitimement ajuster.
- (d) *Quelle part de tout cela les données seules peuvent-elles révéler ?* Considérez les trois diagrammes causaux sur (X, Y, Z) : la chaîne $X \rightarrow Z \rightarrow Y$, la fourche $X \leftarrow Z \rightarrow Y$ et le collider $X \rightarrow Z \leftarrow Y$. Démontrez que les deux premiers impliquent $X \perp Y \mid Z$ tandis que le troisième implique $X \perp Y$ et généralement pas $X \perp Y \mid Z$. Concluez que le collider est détectable à partir de la loi conjointe des observables mais qu'un facteur de confusion ne peut pas être distingué d'un médiateur — de sorte qu'ajuster par un médiateur détruit un effet réel exactement comme ajuster par un collider en invente un faux, et qu'aucune quantité de données ne vous dira lequel des deux vous êtes en train de faire.

Joseph Berkson, médecin et statisticien à la Mayo Clinic, publia la partie (a) en 1946 pour expliquer pourquoi les associations entre maladies relevées dans les dossiers hospitaliers ne sont pas fiables, et David Sackett confirma plus tard l'effet empiriquement sous le nom de « biais d'admission ». Judea Pearl a donné au phénomène son nom moderne et son critère graphique, et la partie (d) est la raison pour laquelle ses diagrammes causaux ne sont pas décoratifs : les indépendances conditionnelles que les données peuvent révéler ne déterminent pas la structure causale, de sorte que le choix des variables à ajuster est une hypothèse, formulée avant l'analyse. L'enjeu n'est pas académique — on a montré en 2020 que les premières études sur la gravité du COVID-19 fondées sur des patients hospitalisés ou testés étaient déformées par exactement ce mécanisme, et le fameux « paradoxe de l'obésité » en cardiologie est largement tenu pour un biais de collider déguisé.

Références :

- Contexte : Paradoxe de Berkson — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Berkson%27s_paradox)
- Contexte : Collisionneur (statistiques) — Wikipédia ([https://fr.wikipedia.org/wiki/Collisionneur_\(statistiques\)](https://fr.wikipedia.org/wiki/Collisionneur_(statistiques)))
- Article : J. Berkson, « Limitations of the application of fourfold table analysis to hospital data », *Biometrics Bulletin* 2 (1946), 47–53
- Article : G. Griffith et al., « Collider bias undermines our understanding of COVID-19 disease risk and severity », *Nature Communications* 11 (2020), 5749

Master

Problème 22 (Pourquoi le bootstrap fonctionne — et quand il échoue — Master). **STA-12. Problème.** Soient $x_1, \dots, x_n$ des tirages indépendants d'une loi F , et soit $\hat{F}_n$ la loi empirique

qui met la masse $1/n$ sur chaque observation. Le bootstrap estime la loi d'échantillonnage d'une statistique sous F par sa loi d'échantillonnage sous $\hat{F}_n$, que l'on peut simuler par rééchantillonnage.

- (a) Démontrez que pour chaque t fixé, $\hat{F}_n(t) \rightarrow F(t)$ presque sûrement, et énoncez le théorème de Glivenko-Cantelli qui rend cette convergence uniforme en t . Expliquez, en un paragraphe précis, comment le « principe de substitution » (plug-in) transforme cela en justification heuristique du bootstrap.
- (b) Cassez-le maintenant. Soit F la loi uniforme sur $(0, \theta)$ et prenons pour statistique le maximum de l'échantillon M_n . Montrez que $P(M_n^* = M_n) = 1 - (1 - 1/n)^n \rightarrow 1 - 1/e \approx 0,632$, où M_n^* est le maximum d'un rééchantillon bootstrap — de sorte que la loi bootstrap du maximum (renormalisé) a un atome de masse environ 0,632 en zéro, alors que la vraie loi limite de $n(\theta - M_n)/\theta$ est une loi exponentielle continue. Concluez que le bootstrap est inconsistant pour l'extrême.
- (c) Expliquez, au niveau des idées, quelle caractéristique des statistiques « régulières » comme les moyennes et les quantiles fait défaut au maximum.

Bradley Efron a introduit le bootstrap dans un article des *Annals of Statistics* de 1979 au titre désarmant de modestie, et il est devenu l'un des outils les plus utilisés de l'âge informatique : un substitut universel aux calculs analytiques de théorie de l'échantillonnage. Mais c'est un théorème, pas de la magie — les démonstrations de consistance (Bickel-Freedman, Singh, 1981) ont des hypothèses, et le maximum de l'échantillon est le contre-exemple standard qui montre qu'elles sont nécessaires. Comprendre les deux moitiés de ce problème, c'est comprendre le bootstrap.

Références :

- Contexte : Bootstrap (statistiques) — Wikipédia ([https://fr.wikipedia.org/wiki/Bootstrap_\(statistiques\)](https://fr.wikipedia.org/wiki/Bootstrap_(statistiques)))
- Lecture : B. Efron & T. Hastie, *Computer Age Statistical Inference*, ch. 10–11 (PDF gratuit sur le site du livre (<https://hastie.su.domains/CASI/>))
- Lecture : L. Wasserman, *All of Statistics*, ch. 8
- Article : B. Efron, « Bootstrap methods : Another look at the jackknife », *Annals of Statistics* 7 (1979), 1–26

Problème 23 (Exhaustivité et Rao-Blackwell — Master). **STA-13. Problème.** Une statistique T est exhaustive pour un paramètre θ si la loi conditionnelle des données sachant T ne dépend pas de θ .

- (a) Démontrez le théorème de factorisation dans le cas discret : T est exhaustive si et seulement si la vraisemblance se factorise en $g(T(x), \theta) h(x)$. Utilisez-le pour montrer que $\sum_i x_i$ est exhaustive pour des échantillons de Bernoulli et de Poisson.
- (b) Démontrez le théorème de Rao-Blackwell : si W est un estimateur sans biais d'une quantité $\tau(\theta)$ et si T est exhaustive, alors $W' = \mathbb{E}[W \mid T]$ est une véritable statistique (elle ne dépend pas de θ), est sans biais, et a une variance au plus égale à celle de W — strictement plus petite sauf si W était déjà une fonction de T .
- (c) Faites tourner la machine : pour des données de Poisson(λ), partez de l'estimateur sans biais grossier $\mathbf{1}\{x_1 = 0\}$ de $e^{-\lambda} = P(X = 0)$, conditionnez par $T = \sum_i x_i$, et établissez l'estimateur amélioré $\left(\frac{n-1}{n}\right)^T$. Vérifiez directement qu'il est sans biais.

L'exhaustivité est l'idée la plus profonde de Fisher (1920–22) : une statistique qui extrait des données jusqu'à la dernière goutte d'information sur θ . Rao (1945) et Blackwell (1947) en ont fait indépendamment un dispositif d'amélioration — conditionnez n'importe quel estimateur honnête

par une statistique exhaustive et vous ne pouvez que gagner. La partie (c) est le tour de passe-passe classique : un estimateur qui ne regarde que la première observation est transformé, par pur conditionnement, en un excellent estimateur. Combinée à la complétude (Lehmann-Scheffé), cette machine produit les meilleurs estimateurs sans biais.

Références :

- Contexte : Théorème de Rao-Blackwell — Wikipédia (https://fr.wikipedia.org/wiki/Th%C3%A9or%C3%A8me_de_Rao-Blackwell)
- Contexte : Statistique exhaustive — Wikipédia (https://fr.wikipedia.org/wiki/Statistique_exhaustive)
- Lecture : G. Casella & R. L. Berger, *Statistical Inference*, 2e éd., ch. 6–7

Problème 24 (Information de Fisher et borne de Cramér-Rao — Master). **STA-14. Problème.** Pour un modèle statistique régulier de densité $f(x; \theta)$, le score est la dérivée de la log-vraisemblance en θ , et l'information de Fisher $I(\theta)$ est la variance du score.

- (a) Sous les conditions de régularité usuelles (dérivation sous le signe intégral), démontrez que le score est d'espérance nulle et que $I(\theta)$ est aussi égale à l'opposé de l'espérance de la dérivée seconde de la log-vraisemblance.
- (b) Démontrez l'inégalité de Cramér-Rao : tout estimateur sans biais W de θ fondé sur n observations indépendantes vérifie $\text{Var}(W) \geq \frac{1}{nI(\theta)}$. (Le cur de la démonstration est l'inégalité de Cauchy-Schwarz appliquée à la covariance de W avec le score.) (c) Calculez $I(\theta)$ pour les modèles Bernoulli(p), Poisson(λ) et $N(\mu, \sigma^2)$ à σ connu, et exhibez dans chaque cas un estimateur sans biais atteignant la borne. (d) Expliquez (démonstration non exigée) en quel sens l'EMV est asymptotiquement normal de variance $\frac{1}{nI(\theta)}$ — la justification ultime de STA-05.

L'information de Fisher, introduite dans les articles de Fisher de 1922–25, est la courbure de la vraisemblance : des vraisemblances pointues épinglent le paramètre. La borne inférieure fut démontrée par C. R. Rao (1945) et figure dans le traité de Harald Cramér de 1946 ; elle marque la frontière exacte de ce que l'estimation sans biais peut atteindre, et l'information de Fisher traverse aujourd'hui la statistique, la théorie de l'information et jusqu'à la géométrie des familles de lois (géométrie de l'information). Gardez ce problème en tête lorsque vous rencontrerez STA-15, qui montre ce qui arrive quand on abandonne l'absence de biais.

Références :

- Contexte : Borne de Cramér-Rao — Wikipédia (https://fr.wikipedia.org/wiki/Borne_de_Cram%C3%A9r-Rao)
- Contexte : Information de Fisher — Wikipédia (https://fr.wikipedia.org/wiki/Information_de_Fisher)
- Lecture : G. Casella & R. L. Berger, *Statistical Inference*, 2e éd., ch. 7 et 10

Problème 25 (Le paradoxe de James-Stein — Master). **STA-15. Problème.** On observe un unique $X = (X_1, \dots, X_p)$ à composantes indépendantes $X_i \sim N(\theta_i, 1)$, et l'on estime le vecteur entier θ sous la perte quadratique totale. L'estimateur évident est X lui-même, de risque constant p . L'estimateur de James-Stein rétrécit vers l'origine :

$$\delta(X) = \left(1 - \frac{p-2}{\|X\|^2}\right) X, \quad \|X\|^2 = \sum_{i=1}^p X_i^2.$$

(a) Démontrez l'identité de Stein : pour g suffisamment régulière avec $\mathbb{E}|\partial g/\partial x_i|$ finie, $\mathbb{E}[(X_i - \theta_i)g(X)] = \mathbb{E}[\partial g/\partial x_i]$. (b) Utilisez-la pour calculer le risque de δ et démontrez que pour $p \geq 3$,

$$\mathbb{E}\|\delta(X) - \theta\|^2 = p - (p-2)^2 \mathbb{E}\left[\frac{1}{\|X\|^2}\right] < p \quad \text{pour tout } \theta$$

— l'estimateur naturel est inadmissible en dimension trois ou plus. (c) Expliquez pourquoi l'argument échoue pour $p = 2$, et méditez le scandale : estimer la moyenne au bâton d'un joueur en utilisant les moyennes de joueurs sans rapport diminue l'erreur totale. Où exactement l'« emprunt de force » entre-t-il dans la mathématique ?

Charles Stein annonça en 1956 que le vecteur des moyennes empiriques est inadmissible en dimension ≥ 3 , et avec Willard James exhiba en 1961 l'estimateur dominant explicite ci-dessus. Cela reste le théorème le plus contre-intuitif de la statistique : ni l'absence de biais ni aucun principe d'optimalité n'y survit sans réserve. L'article d'Efron et Morris de 1977 dans *Scientific American* l'a rendu célèbre avec des données de baseball, et ses descendants intellectuels — bayésien empirique, rétrécissement, régression ridge, modèles hiérarchiques — sont l'ossature de l'estimation moderne à grande échelle.

Références :

- Contexte : Estimateur de James-Stein — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/James%E2%80%93Stein_estimator)
- Lecture : B. Efron & T. Hastie, *Computer Age Statistical Inference*, ch. 7 (PDF gratuit sur le site du livre (<https://hastie.su.domains/CASI/>))
- Article : B. Efron & C. Morris, « Stein's paradox in statistics », *Scientific American* 236 (1977), 119–127
- Article : W. James & C. Stein, « Estimation with quadratic loss », *Proc. Fourth Berkeley Symposium* (1961), 361–379

Problème 26 (La méthode delta — Master, short). **STA-25. Problème.** Supposons que $\sqrt{n}(T_n - \theta)$ converge en loi vers $N(0, \sigma^2)$ et que g soit dérivable en θ avec $g'(\theta) \neq 0$. Démontrez que

$$\sqrt{n}(g(T_n) - g(\theta)) \xrightarrow{d} N(0, g'(\theta)^2 \sigma^2),$$

en précisant explicitement où le théorème de Slutsky est utilisé, et appliquez-le pour trouver la loi limite de la cote empirique $\hat{p}/(1-\hat{p})$ pour des données de Bernoulli(p) indépendantes avec $0 < p < 1$.

C'est le théorème de Taylor faisant de la statistique : une fonction régulière d'un estimateur asymptotiquement normal est asymptotiquement normale, avec la variance multipliée par le carré de la dérivée. Les physiciens du XIXe siècle connaissaient cela sous le nom de propagation des erreurs ; Cramér en donna l'énoncé moderne en 1946. Presque toute erreur type que vous lirez sur une sortie d'ordinateur pour un rapport, un log-odds, une corrélation ou une probabilité de survie a été produite par cet argument — et lorsque $g'(\theta) = 0$ il échoue et la limite devient une loi du khi-deux, ce qui vaut la peine d'être découvert par soi-même.

Références :

- Contexte : Méthode delta — Wikipédia (https://fr.wikipedia.org/wiki/M%C3%A9thode_delta)
- Lecture : A. W. van der Vaart, *Asymptotic Statistics*, ch. 3
- Lecture : G. Casella & R. L. Berger, *Statistical Inference*, 2e éd., ch. 5

Problème 27 (Biais et variance, en une seule identité — Master, short). **STA-26. Problème.** Soit $Y = f(x) + \varepsilon$ en un point fixé x , avec $\mathbb{E}[\varepsilon] = 0$ et $\text{Var}(\varepsilon) = \sigma^2$, et soit $\hat{f}$ une estimation de f construite à partir d'un échantillon d'apprentissage indépendant de ε . Démontrez la décomposition

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \sigma^2 + (\mathbb{E}[\hat{f}(x)] - f(x))^2 + \text{Var}(\hat{f}(x)),$$

et servez-vous-en pour expliquer précisément pourquoi un estimateur biaisé peut avoir une erreur de prédiction plus petite que tous les estimateurs sans biais.

Trois lignes de calcul, et elles réorganisent toute une discipline : le premier terme est irréductible, le deuxième est ce que vous achetez en simplifiant votre modèle, le troisième est ce que vous payez pour la souplesse. L'identité est la justification honnête des estimateurs à rétrécissement de STA-15 et de toute pénalité de régularisation en apprentissage automatique ; Geman, Bienenstock et Doursat ont baptisé le compromis correspondant « dilemme biais-variance » en 1992. Elle a aussi une variante moderne qui mérite lecture : les modèles très surparamétrés présentent une seconde descente de l'erreur de test au-delà du point d'interpolation, de sorte que l'image classique en U est un cas particulier plutôt qu'une loi.

Références :

- Contexte : Dilemme biais-variance — Wikipédia (https://fr.wikipedia.org/wiki/Dilemme_biais-variance)
- Article : S. Geman, E. Bienenstock & R. Doursat, « Neural networks and the bias/variance dilemma », *Neural Computation* 4 (1992), 1–58
- Lecture : T. Hastie, R. Tibshirani & J. Friedman, *The Elements of Statistical Learning*, ch. 7 (PDF gratuit sur le site du livre (<https://hastie.su.domains/ElemStatLearn/>))

Problème 28 (Ce que mesure vraiment une courbe ROC — Master). **STA-27. Problème.** Un détecteur attribue à chaque objet un score réel $s(X)$. Soit X_1 un objet tiré au hasard dans la classe positive et X_0 un objet de la classe négative, et pour un seuil t posons

$$\text{TPR}(t) = P(s(X_1) \geq t), \quad \text{FPR}(t) = P(s(X_0) \geq t).$$

La courbe ROC est l'ensemble des points $(\text{FPR}(t), \text{TPR}(t))$ lorsque t parcourt $\mathbb{R}$, et l'AUC est l'aire sous cette courbe.

- (a) Démontrez que la courbe ROC est inchangée si l'on remplace le score par $h(s(X))$ pour toute h strictement croissante — la courbe ROC ne voit donc que l'ordre des objets, jamais la calibration des scores.
- (b) Démontrez l'identité probabiliste

$$\text{AUC} = P(s(X_1) > s(X_0)) + \frac{1}{2}P(s(X_1) = s(X_0)),$$

et identifiez sa version empirique comme la statistique U de Mann-Whitney divisée par le produit des tailles d'échantillon.

- (c) Supposons que les deux classes aient les densités f_1 et f_0 . Démontrez que la courbe ROC du score du rapport de vraisemblance $s^*(x) = f_1(x)/f_0(x)$ est au-dessus ou confondue avec la courbe ROC de tout autre score — c'est le lemme de Neyman-Pearson (STA-09) lu comme un énoncé sur des courbes — et démontrez que cette courbe optimale est concave, sa pente au point de fonctionnement valant le seuil de rapport de vraisemblance correspondant.
- (d) Voici maintenant le piège pratique : démontrez que l'AUC ne change pas lorsque la proportion de positifs dans la population change, alors que la précision $P(\text{positif} \mid \text{signalé})$ change. Construisez deux problèmes de dépistage ayant des courbes ROC identiques dont l'un est utile et l'autre déclenche cent fausses alertes par cas réel, et énoncez la morale quant à la publication d'un chiffre unique.

La caractéristique de fonctionnement du récepteur est née du radar : pendant la Seconde Guerre mondiale, la question était de savoir comment régler le seuil de décision d'un opérateur quand un écho peut être un avion ou du bruit, et la théorie fut rédigée par Peterson, Birdsall et Fox en 1954. Green et Swets la portèrent en psychologie expérimentale, et l'article de Hanley et McNeil de 1982 — qui a fait connaître l'équivalence de (b) — l'a rendue standard en radiologie puis dans tous les domaines qui évaluent des classificateurs. La mathématique de (c) est un théorème centenaire en costume moderne ; l'avertissement de (d) explique que l'AUC soit à la fois le nombre le plus rapporté et le plus critiqué de l'apprentissage automatique appliqué.

Références :

- Contexte : Courbe ROC — Wikipédia (https://fr.wikipedia.org/wiki/Courbe_ROC)
- Contexte : Test de Wilcoxon-Mann-Whitney — Wikipédia (https://fr.wikipedia.org/wiki/Test_de_Wilcoxon-Mann-Whitney)
- Article : J. A. Hanley & B. J. McNeil, « The meaning and use of the area under a receiver operating characteristic (ROC) curve », *Radiology* 143 (1982), 29–36
- Lecture : D. M. Green & J. A. Swets, *Signal Detection Theory and Psychophysics* (1966)

Problème 29 (Un estimateur minimax pour une pièce — Master, short). **STA-35. Problème.** Soit $X \sim \text{Binomial}(n, p)$ et estimons p sous la perte quadratique, de sorte que le risque d'un estimateur δ vaut $R(p, \delta) = E_p[(\delta(X) - p)^2]$. Démontrez qu'un estimateur de Bayes dont la fonction de risque est constante en p est minimax, puis démontrez que l'estimateur de Bayes pour la loi a priori $\text{Beta}(\sqrt{n}/2, \sqrt{n}/2)$,

$$\delta^*(X) = \frac{X + \sqrt{n}/2}{n + \sqrt{n}},$$

a un risque constant et est donc minimax ; comparez enfin $R(p, \delta^*)$ au risque de la proportion empirique X/n et déterminez pour quels p l'estimateur ordinaire est meilleur.

Abraham Wald a bâti la statistique comme un jeu à deux joueurs contre la nature dans les années 1940 (*Statistical Decision Functions*, 1950), et la règle minimax est le coup du pessimiste : choisir la procédure dont le pire cas est le moins mauvais. Le procédé employé ici — trouver une loi a priori dont la règle de Bayes a un risque plat, et le pire cas n'a alors nulle part où se cacher — est la voie standard vers la minimaxité, et la loi a priori qui fait cela s'appelle la moins favorable. Hodges et Lehmann ont traité ce cas et des cas voisins en 1950. La comparaison finale est la coda honnête : l'estimateur minimax rétrécit vers $1/2$ et ne bat la proportion empirique qu'au voisinage du milieu de l'intervalle, ce qui rappelle que la minimaxité est une garantie sur le pire cas et non une recommandation pour tous les cas.

Références :

- Contexte : Estimateur minimax — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Minimax_estimator)
- Article : J. L. Hodges & E. L. Lehmann, « Some problems in minimax point estimation », *Annals of Mathematical Statistics* 21 (1950), 182–197
- Lecture : E. L. Lehmann & G. Casella, *Theory of Point Estimation*, 2e éd., ch. 5

Problème 30 (Pourquoi l'algorithme EM grimpe — Master). **STA-36. Problème.** Supposons que les données observées y soient une fonction de données complètes (y, z) où z n'est pas observé, et écrivons $\ell(\theta) = \log p(y | \theta)$. L'algorithme EM itère les deux étapes

$$Q(\theta | \theta^{(t)}) = E[\log p(y, z | \theta) | y, \theta^{(t)}], \quad \theta^{(t+1)} = \arg \max_{\theta} Q(\theta | \theta^{(t)}).$$

- (a) Démontrez la propriété de croissance. Montrez que $\ell(\theta) = Q(\theta | \theta') - H(\theta | \theta')$ où $H(\theta | \theta') = E[\log p(z | y, \theta) | y, \theta']$, démontrez à l'aide de l'inégalité de Jensen que $H(\theta' | \theta') - H(\theta | \theta')$ est une divergence de Kullback-Leibler, donc positive, et concluez que $\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$ pour tout t — la vraisemblance des données observées ne décroît jamais, quel que soit le modèle.
- (b) Démontrez l'identité d'énergie libre : pour toute loi q sur la variable latente,

$$\ell(\theta) = \underbrace{E_q[\log p(y, z | \theta)] + \mathcal{H}(q)}_{F(q, \theta)} + \text{KL}(q \| p(z | y, \theta)),$$

où $\mathcal{H}(q)$ est l'entropie de q , et déduisez-en que EM est exactement une montée par coordonnées sur F : l'étape E maximise en q , l'étape M en θ .

- (c) Traitez un exemple : pour un mélange gaussien univarié à deux composantes d'espérances, variances et poids de mélange inconnus, établissez les responsabilités de l'étape E et montrez que l'étape M est un maximum de vraisemblance pondéré ordinaire. Démontrez ensuite que cette vraisemblance n'est pas bornée — envoyez l'espérance d'une composante sur un point de données et sa variance vers zéro — de sorte que « EM converge vers l'estimateur du maximum de vraisemblance » ne peut pas être vrai tel quel.
- (d) Dites précisément ce qui est vrai. Donnez un exemple à plusieurs maxima locaux où EM converge vers des points différents selon le point de départ, énoncez le théorème de Wu de 1983 sur la convergence vers un point stationnaire de ℓ sous conditions de régularité, et expliquez ce que la propriété de croissance de (a) garantit et ne garantit pas au sujet de la suite $\theta^{(t)}$ elle-même.

Dempster, Laird et Rubin ont nommé l'algorithme et démontré la propriété de croissance en 1977, unifiant une douzaine de procédures inventées séparément — celle de Hartley pour les données groupées (1958), l'algorithme de Baum-Welch pour les modèles de Markov cachés (1970), l'estimation de fréquences géniques, l'analyse factorielle — en une seule recette dont le seul ingrédient est la capacité de calculer une espérance conditionnelle. C'est l'un des articles les plus cités de la statistique. Son argument de convergence n'était toutefois pas étanche : C. F. Jeff Wu signala la faille en 1983 et fournit l'énoncé correct, ce qui est l'objet de la partie (d) — une suite croissante de valeurs de la vraisemblance ne dit rien à elle seule sur la convergence des paramètres, et encore moins sur leur convergence vers un maximum global. La partie (b) est la reformulation de Neal et Hinton de 1998, et c'est la porte d'entrée de l'inférence variationnelle : restreignez q à une famille traitable et la même montée par coordonnées devient le cheval de bataille du calcul bayésien moderne.

Références :

- Contexte : Algorithme espérance-maximisation — Wikipédia (https://fr.wikipedia.org/wiki/Algorithme_esp%C3%A9rance-maximisation)
- Article : A. P. Dempster, N. M. Laird & D. B. Rubin, « Maximum likelihood from incomplete data via the EM algorithm », *Journal of the Royal Statistical Society B* 39 (1977)
- Article : C. F. J. Wu, « On the convergence properties of the EM algorithm », *Annals of Statistics* 11 (1983)
- Lecture : G. McLachlan & T. Krishnan, *The EM Algorithm and Extensions*, 2e éd.

Problème 31 (Survie, censure et une hypothèse que l'on ne peut pas tester — Master). **STA-37. Problème.** Chaque sujet i possède un temps de survie T_i et un temps de censure C_i ; on n'observe que $Y_i = \min(T_i, C_i)$ et l'indicatrice $\delta_i = \mathbf{1}\{T_i \leq C_i\}$. Notons $S(t) = P(T > t)$ la fonction de survie à estimer.

- (a) Supposons T_i et C_i indépendants, la loi de C_i ne dépendant pas des paramètres d'intérêt. Démontrez que la vraisemblance se factorise en $\prod_i f(y_i)^{\delta_i} S(y_i)^{1-\delta_i}$ multiplié par un terme ne faisant pas intervenir S , de sorte que le mécanisme de censure peut être ignoré. Énoncez exactement ce que la censure indépendante affirme au sujet du monde, et expliquez pourquoi c'est une hypothèse sur des mécanismes plutôt qu'une propriété des données observées.
- (b) Établissez l'estimateur de Kaplan-Meier

$$\hat{S}(t) = \prod_{j: t_j \leq t} \left(1 - \frac{d_j}{n_j}\right),$$

où $t_1 < t_2 < \dots$ sont les instants de défaillance observés distincts, d_j le nombre de défaillances en t_j et n_j le nombre de sujets encore à risque juste avant, en maximisant la vraisemblance de (a) sur toutes les lois portées par les instants de défaillance observés. Établissez ensuite la formule de Greenwood pour la variance de $\hat{S}(t)$ en appliquant la méthode delta (STA-25) à $\log \hat{S}(t)$.

- (c) Le modèle de Cox attribue au sujet i de vecteur de covariables x_i le risque instantané $\lambda(t | x_i) = \lambda_0(t) e^{\beta^\top x_i}$ où λ_0 est une fonction inconnue arbitraire. Établissez la vraisemblance partielle

$$L(\beta) = \prod_{i: \delta_i=1} \frac{e^{\beta^\top x_i}}{\sum_{j \in R(t_i)} e^{\beta^\top x_j}}, \quad R(t) = \{j : Y_j \geq t\},$$

démontrez que λ_0 en a entièrement disparu, et démontrez que son score est d'espérance nulle en la vraie valeur de β . Énoncez ensuite quelle quantité est estimée lorsque l'hypothèse de risques proportionnels est fausse.

- (d) Démontrez ou reconstruisez le théorème de Tsiatis (1975) : pour toute loi conjointe de (T, C) — avec une dépendance arbitraire — il existe un modèle où T et C sont indépendants qui produit exactement la même loi des observables (Y, δ) . Concluez que la censure indépendante n'est pas testable à partir des données, et discutez de ce à quoi devrait ressembler une analyse de sensibilité pour cette hypothèse.

Les tables de mortalité sont plus anciennes que la statistique — John Graunt a dressé celle de Londres en 1662 et Halley celle de Breslau en 1693 — mais la censure, le fait qu'une étude s'achève alors que des sujets sont encore en vie, fut traitée par des recettes actuarielles ad hoc jusqu'à ce qu'Edward Kaplan et Paul Meier soumettent indépendamment au *JASA* des articles presque identiques ; le rédacteur en chef les obligea à fusionner, et après quatre ans de discussions l'article de 1958 parut. Il est parmi les plus cités de l'histoire des sciences, tout comme la vraisemblance partielle de David Cox de 1972, si nouvelle que Cox dut écrire un second article en 1975 pour expliquer pourquoi on peut traiter une vraisemblance partielle comme une vraisemblance. La partie (d) est l'ombre permanente du domaine : l'hypothèse qui fait tout fonctionner — que les gens quittent une étude pour des raisons sans rapport avec leur pronostic — ne peut pas être vérifiée sur les données, seulement argumentée.

Références :

- Contexte : Estimateur de Kaplan-Meier — Wikipédia (https://fr.wikipedia.org/wiki/Estimateur_de_Kaplan-Meier)
- Contexte : Régression de Cox (modèle à risques proportionnels) — Wikipédia (https://fr.wikipedia.org/wiki/R%C3%A9gression_de_Cox)
- Article : E. L. Kaplan & P. Meier, « Nonparametric estimation from incomplete observations », *Journal of the American Statistical Association* 53 (1958), 457–481

- Article : D. R. Cox, « Regression models and life-tables », *Journal of the Royal Statistical Society B* 34 (1972), 187–202 ; A. Tsiatis, « A nonidentifiability aspect of the problem of competing risks », *PNAS* 72 (1975), 20–22

Problème 32 (AIC et BIC répondent à des questions différentes — Master). **STA-38. Problème.** *Un modèle à k paramètres libres est ajusté à n observations indépendantes, donnant la log-vraisemblance maximisée $\hat{\ell}$. Les deux critères de sélection classiques sont*

$$\text{AIC} = -2\hat{\ell} + 2k, \quad \text{BIC} = -2\hat{\ell} + k \log n.$$

Ils ne diffèrent que par une pénalité, et ils sont dérivés de cibles complètement différentes.

- (a) *Établissez l'AIC. Prenez pour cible la divergence de Kullback-Leibler moyenne de la vérité au modèle ajusté, autrement dit la log-vraisemblance moyenne du modèle ajusté sur une copie indépendante des données. Montrez que $\hat{\ell}$ surestime cette cible, et démontrez sous les conditions de régularité usuelles — un développement quadratique de la log-vraisemblance plus la normalité asymptotique de l'estimateur du maximum de vraisemblance (STA-14) — que le biais vaut asymptotiquement k .*
- (b) *Établissez le BIC. Appliquez l'approximation de Laplace à la vraisemblance marginale $m(y) = \int p(y | \theta) \pi(\theta) d\theta$ et démontrez que*

$$\log m(y) = \hat{\ell} - \frac{k}{2} \log n + O(1),$$

de sorte que comparer des valeurs de BIC approche la comparaison des probabilités a posteriori des modèles ; montrez que la loi a priori π ne contribue qu'au terme $O(1)$.

- (c) *Voyez la conséquence dans le cas le plus simple. Pour n observations de $N(\mu, 1)$, comparez les deux critères sur le couple emboîté $\{\mu = 0\}$ contre $\{\mu \in \mathbb{R}\}$: démontrez que lorsque $\mu = 0$ la règle du BIC choisit le bon modèle avec une probabilité tendant vers 1, tandis que la règle de l'AIC choisit le plus grand modèle avec une probabilité qui ne s'annule pas, et identifiez la valeur limite de cette probabilité. Démontrez ensuite, ou énoncez fidèlement, le résultat de Stone de 1977 selon lequel l'AIC est asymptotiquement équivalent à la validation croisée « un contre tous ».*
- (d) *Énoncez précisément le théorème de Yang (2005) : aucune procédure de sélection de modèle ne peut être simultanément consistante pour identifier un vrai modèle de dimension finie et optimale au sens des vitesses minimax pour estimer la fonction de régression — les forces du BIC et celles de l'AIC ne peuvent pas être combinées. Puis, pour un problème appliqué concret de votre choix, dites lequel des deux objectifs est réellement le vôtre.*

Hirotsugu Akaike proposa son critère lors d'un colloque en 1971 et le publia en 1974, ayant compris que la vraisemblance maximisée est une estimation biaisée de l'ajustement prédictif et que le biais vaut, chose remarquable, tout juste le nombre de paramètres. Gideon Schwarz établit l'autre pénalité en 1978 par un argument bayésien où la taille de l'échantillon entre par le rétrécissement de la loi a posteriori. On s'est ensuite disputé à leur sujet pendant quarante ans comme si l'un des deux devait avoir tort, mais la partie (d) tranche le débat de la seule façon dont les mathématiques le peuvent : ils optimisent des critères différents, et le théorème d'impossibilité de Yuhong Yang démontre qu'aucun critère n'optimise les deux. C'est un bon modèle de la manière dont s'achève une controverse méthodologique — non par un vainqueur, mais par un théorème décrivant l'arbitrage qu'aucun des deux camps ne pouvait éviter.

Références :

- Contexte : Critère d'information d'Akaike — Wikipédia (https://fr.wikipedia.org/wiki/Crit%C3%A8re_d'information_d'Akaike)
- Contexte : Critère d'information bayésien — Wikipédia (https://fr.wikipedia.org/wiki/Crit%C3%A8re_d'information_bay%C3%A9sien)
- Article : H. Akaike, « A new look at the statistical model identification », *IEEE Transactions on Automatic Control* 19 (1974), 716–723 ; G. Schwarz, « Estimating the dimension of a model », *Annals of Statistics* 6 (1978)
- Article : Y. Yang, « Can the strengths of AIC and BIC be shared ? », *Biometrika* 92 (2005), 937–950

Recherche

Problème 33 (L'inférence après sélection — Recherche). **STA-16. Problème.** *La pratique moderne choisit la question après avoir vu les données — le plus grand effet, le meilleur modèle — puis rapporte l'inférence comme si la question avait été fixée d'avance. Rendez les dégâts précis, puis passez les réparations en revue.*

- Soient $X_1, \dots, X_m$ indépendantes $N(\mu_i, 1)$ et supposons que tous les $\mu_i = 0$. Vous sélectionnez l'indice du plus grand X_i et publiez la borne de confiance inférieure naïve à 95 % $X_{(m)} - 1,645$ pour l'espérance sélectionnée. Démontrez que la couverture vaut $\Phi(1,645)^m$, soit environ 0,90 pour $m = 2$ et qui s'effondre vers 0 quand m croît. Montrez aussi que $\mathbb{E}[\max(X_1, X_2)] = 1/\sqrt{\pi} > 0$, de sorte que l'estimation sélectionnée est biaisée par excès alors même que toutes les vraies espérances sont nulles (la malédiction du vainqueur).
- Problème de compréhension : lisez comment on restaure une inférence post-sélection valide — inférence simultanée sur tous les modèles (Berk et al. 2013) et « inférence sélective » conditionnelle exacte pour des procédures comme le lasso (école de Taylor et Tibshirani) — et rédigez une comparaison de ce que chacune garantit, et à quel prix en largeur d'intervalle. État des lieux : domaine de recherche actif depuis 2013 environ ; aucun cadre unique n'est encore la pratique standard, et étendre l'inférence sélective exacte au-delà de procédures particulières reste un territoire ouvert.

Le problème est aussi ancien que le tripatouillage des données, mais il est devenu aigu quand la sélection de modèle est devenue automatique : le lasso, la régression pas à pas et les balayages pangénomiques choisissent tous les hypothèses de façon adaptative. L'article de 2013 de Berk, Brown, Buja, Zhang et Zhao a donné la première réponse fréquentiste pleinement honnête (« PoSI »), et l'inférence sélective conditionnelle a suivi rapidement. C'est le domaine où la mathématique de la crise de la reproductibilité (STA-17) se répare, une procédure à la fois.

Références :

- Contexte : Data dredging (trituration de données) — Wikipédia (https://fr.wikipedia.org/wiki/Data_dredging)
- Article : R. Berk, L. Brown, A. Buja, K. Zhang & L. Zhao, « Valid post-selection inference », *Annals of Statistics* 41 (2013), 802–837
- Article : J. Taylor & R. J. Tibshirani, « Statistical learning and selective inference », *PNAS* 112 (2015), 7629–7634

Problème 34 (La crise de la reproductibilité comme statistique mathématique — Recherche). **STA-17. Problème.** *Vers 2011–2015, il est apparu qu'une large part des résultats publiés en psychologie, en médecine et ailleurs ne se reproduisent pas. Traitez cela comme un domaine où l'on démontre des théorèmes, pas comme un scandale.*

- (a) Un domaine teste de nombreuses hypothèses, dont une fraction π correspond à de vrais effets ; les tests ont un niveau α et une puissance $1 - \beta$. Établissez la valeur prédictive positive

$$\text{PPV} = \frac{\pi(1 - \beta)}{\pi(1 - \beta) + (1 - \pi)\alpha},$$

et évaluez-la pour $\pi = 0,1$, $\alpha = 0,05$, puissance $0,8$. Concluez que des résultats « significatifs » peuvent être faux plus d'une fois sur trois même avec une pratique irréprochable — c'est l'argument d'Ioannidis de 2005 rendu rigoureux.

- (b) Démontrez que la procédure de Benjamini-Hochberg contrôle le taux de fausses découvertes au niveau q lorsque les valeurs p des vraies hypothèses nulles sont indépendantes et uniformes.
- (c) Démontrez que l'arrêt optionnel détruit la significativité naïve : pour des observations indépendantes $N(\theta, 1)$ avec $\theta = 0$, la loi du logarithme itéré implique que la statistique z courante $\sqrt{n}\bar{x}_n$ dépasse tout seuil fixé une infinité de fois, presque sûrement — de sorte que « tester après chaque observation et s'arrêter à la significativité » rejette une hypothèse nulle vraie avec probabilité 1. État des lieux : (a)–(c) sont des mathématiques établies ; concevoir une inférence robuste au biais de publication, au p -hacking et à l'analyse adaptative est un front de recherche ouvert et actif (voir STA-16 et STA-18).

L'essai d'Ioannidis de 2005 « Why most published research findings are false » et la réplique par l'Open Science Collaboration en 2015 de 100 études de psychologie (39 % des résultats significatifs répliqués) ont défini la crise. Les réponses mathématiques — taux de fausses découvertes (Benjamini-Hochberg 1995), inférence post-sélection, préenregistrement, méthodes valides à tout instant — comptent parmi les statistiques les plus conséquentes que l'on fasse aujourd'hui : les théorèmes présentés ici sont la raison pour laquelle la crise a pu être diagnostiquée.

Références :

- Contexte : Crise de la reproductibilité — Wikipédia (https://fr.wikipedia.org/wiki/Crise_de_la_reproductibilit%C3%A9)
- Article : J. P. A. Ioannidis, « Why most published research findings are false », *PLoS Medicine* 2 (2005), e124
- Article : Y. Benjamini & Y. Hochberg, « Controlling the false discovery rate », *Journal of the Royal Statistical Society B* 57 (1995), 289–300
- Article : Open Science Collaboration, « Estimating the reproducibility of psychological science », *Science* 349 (2015), aac4716

Problème 35 (Valeurs e et tests sûrs — Recherche). **STA-18. Problème.** Une variable e pour une hypothèse nulle H_0 est une variable aléatoire positive E telle que $\mathbb{E}_0[E] \leq 1$ sous toute loi de H_0 ; sa valeur réalisée est une valeur e , les grandes valeurs comptant comme preuve contre H_0 .

- (a) Démontrez que rejeter lorsque $E \geq 1/\alpha$ a un risque de première espèce au plus α (inégalité de Markov), et que $\min(1, 1/E)$ est une valeur p conservatrice.
- (b) Démontrez que pour une hypothèse nulle simple de densité f_0 , tout rapport de vraisemblance $f_1(X)/f_0(X)$ est une variable e .
- (c) Voici l'intérêt de tout cela : supposons que des expériences arrivent en séquence et que chaque nouvelle variable e E_k puisse être choisie à partir de toutes les données passées, avec $\mathbb{E}_0[E_k \mid \text{passé}] \leq 1$. Démontrez que le produit courant $M_n = E_1 E_2 \cdots E_n$ est une surmartingale positive sous H_0 , énoncez l'inégalité de Ville $P_0(\sup_n M_n \geq 1/\alpha) \leq \alpha$, et concluez que la preuve empirique peut être accumulée et surveillée en continu, avec arrêt optionnel et poursuite optionnelle, sans rien coûter à la garantie de première espèce — exactement ce que les valeurs p ne peuvent pas faire (STA-17c).

- (d) *Problème de compréhension : lisez la théorie d’optimalité au taux de croissance (GRO) de Grünwald, de Heide et Koolen et expliquez ce qui remplace la « puissance » lorsque les tests se mesurent à la croissance de la valeur e . État des lieux : programme de recherche fondationnel, très actif depuis 2019 ; « Safe testing » a paru avec discussion dans JRSS-B en 2024, et les questions ouvertes abondent (valeurs e optimales pour des hypothèses nulles composites, valeurs e pour des données complexes dépendantes, le bon analogue des intervalles de confiance).*

Les valeurs e renouent le test d’hypothèse avec les martingales et le jeu — la preuve contre l’hypothèse nulle est la fortune d’un joueur qui parie contre elle — une ligne de pensée qui remonte à Ville (1939) et que la probabilité théorie-des-jeux de Shafer et Vovk a ravivée. L’essor moderne a commencé avec « Safe testing » de Grünwald, de Heide et Koolen (prépublication 2019, JRSS-B 2024) et les travaux parallèles de Vovk, Wang, Ramdas et Shafer ; le domaine se range désormais sous la bannière « statistique théorie-des-jeux et inférence sûre valide à tout instant ». C’est la tentative actuelle la plus sérieuse de refonder le test de sorte que la pratique scientifique ordinaire — jeter un il aux données, les mettre en commun, poursuivre — devienne mathématiquement légale.

Références :

- Contexte : Valeurs e — Wikipédia (en anglais) (<https://en.wikipedia.org/wiki/E-values>)
- Article : P. Grünwald, R. de Heide & W. M. Koolen, « Safe testing », *Journal of the Royal Statistical Society B* 86 (2024), 1091–1128, arXiv :1906.07801 (<https://arxiv.org/abs/1906.07801>)
- Article : A. Ramdas, P. Grünwald, V. Vovk & G. Shafer, « Game-theoretic statistics and safe anytime-valid inference », *Statistical Science* 38 (2023), 576–601, arXiv :2210.01948 (<https://arxiv.org/abs/2210.01948>)
- Lecture : G. Shafer & V. Vovk, *Game-Theoretic Foundations for Probability and Finance* (2019)

Problème 36 (Ce que la prédiction conforme peut et ne peut pas promettre — Recherche, short).
STA-28. Problème. *La prédiction conforme par découpage ajuste un prédicteur quelconque sur une partie des données, calcule des scores de conformité $R_1, \dots, R_n$ (par exemple des résidus absolus) sur un ensemble de calibration mis de côté, et pour une nouvelle entrée renvoie l’ensemble des valeurs dont le score tomberait en dessous du $\lceil (n+1)(1-\alpha) \rceil$ -ième plus petit des R_i . Démontrez la garantie de couverture marginale à échantillon fini $P(Y_{n+1} \in C(X_{n+1})) \geq 1 - \alpha$ en supposant seulement que les $n+1$ couples sont échangeables — aucune correction du modèle, aucune hypothèse de loi — puis énoncez précisément le théorème d’impossibilité de Barber, Candès, Ramdas et Tibshirani (2021), à savoir qu’aucune procédure sans hypothèse de loi ne peut atteindre une couverture non triviale conditionnellement à $X_{n+1} = x$.*

La prédiction conforme a été développée par Vovk, Gammerman et Shafer à partir de la fin des années 1990 et est devenue, autour de 2019, la façon standard d’attacher une barre d’erreur honnête à la sortie d’un modèle boîte noire arbitraire, y compris des réseaux de neurones que personne ne sait analyser. La garantie de la première moitié est un argument de permutation en trois lignes ; le théorème de la seconde moitié explique pourquoi les praticiens continuent de réclamer quelque chose que le cadre ne peut démonstrablement pas leur donner gratuitement. État en 2026 : la couverture marginale sous échangeabilité est une mathématique réglée, tandis que les relâchements utiles — couverture conditionnelle approchée, changement de covariables, données dépendantes et séries temporelles — forment une frontière de recherche active.

Références :

- Contexte : Prédiction conforme — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Conformal_prediction)
- Lecture : V. Vovk, A. Gammerman & G. Shafer, *Algorithmic Learning in a Random World* (2005)

- Article : R. F. Barber, E. J. Candès, A. Ramdas & R. J. Tibshirani, « The limits of distribution-free conditional predictive inference », *Information and Inference* 10 (2021), 455–482, arXiv :1903.04684 (<https://arxiv.org/abs/1903.04684>)

Problème 37 (Un écart entre ce qui peut être estimé et ce qui peut être calculé — Recherche, short). **STA-29. Problème.** Dans le modèle de covariance à pic, on observe n tirages indépendants de $N(0, I_p + \theta vv^\top)$, où le vecteur unitaire v a au plus k coordonnées non nulles, et la tâche est de décider si $\theta = 0$ ou $\theta > 0$. Rédigez un compte rendu précis de l'état des lieux : la recherche exhaustive sur tous les supports réussit dès que $n \gtrsim k \log p / \theta^2$, toute méthode connue en temps polynomial exige $n \gtrsim k^2 / \theta^2$, et Berthet et Rigollet (2013) ont démontré que franchir la seconde frontière résoudrait aussi le problème de la clique plantée — de sorte que l'écart apparent n'est réel que conditionnellement à une hypothèse de difficulté en moyenne qui n'est elle-même pas démontrée.

Les écarts calcul-statistique sont l'un des thèmes marquants de la statistique du XXI^e siècle : la théorie classique demande ce qu'une taille d'échantillon rend possible, et ne dit rien de ce qu'un algorithme peut atteindre en temps polynomial. La détection d'une composante principale parcimonieuse en est le cas d'école, et les indices en faveur de l'écart viennent aujourd'hui de plusieurs directions — réductions depuis la clique plantée, bornes inférieures somme-de-carrés, et l'heuristique des polynômes de bas degré — dont aucune n'est une démonstration inconditionnelle. État en 2026 : l'écart est conjectural ; démontrer inconditionnellement qu'un problème d'estimation naturel est difficile en calcul reste hors de portée.

Références :

- Contexte : ACP parcimonieuse — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Sparse_PCA)
- Article : Q. Berthet & P. Rigollet, « Complexity theoretic lower bounds for sparse principal component detection », *Proceedings of COLT 2013*, PMLR 30, 1046–1066, PMLR (<https://proceedings.mlr.press/v30/Berthet13.html>)

Problème 38 (Quand un nombre mérite-t-il le nom d'effet ? — Recherche). **STA-30. Problème.** Dans le modèle des résultats potentiels, chaque unité i porte deux nombres $Y_i(1)$ et $Y_i(0)$ — sa réponse sous traitement et sous contrôle — dont seul $Y_i = Y_i(T_i)$ est observé, où $T_i \in \{0, 1\}$ enregistre le traitement effectivement reçu. L'estimande est l'effet moyen du traitement $\tau = \mathbb{E}[Y(1) - Y(0)]$.

- Démontrez que τ n'est pas déterminé par la loi conjointe des observables (T, Y) : exhibez deux populations de mêmes lois observables et de τ différents. Démontrez ensuite que sous randomisation — T indépendant de $(Y(0), Y(1))$ — la différence des deux moyennes empiriques est sans biais pour τ .
- Supposez plutôt l'absence de confusion sachant des covariables X , c'est-à-dire $T \perp (Y(0), Y(1)) \mid X$, avec la positivité $0 < P(T = 1 \mid X) < 1$ presque sûrement. Démontrez la formule d'ajustement

$$\mathbb{E}[Y(1)] = \mathbb{E}_X [\mathbb{E}[Y \mid T = 1, X]],$$

et démontrez le théorème du score de propension de Rosenbaum et Rubin : l'absence de confusion sachant X implique l'absence de confusion sachant le seul nombre $e(X) = P(T = 1 \mid X)$.

- Énoncez le critère de la porte dérobée (back-door) de Pearl pour un graphe causal et démontrez qu'un ensemble le vérifiant justifie la formule d'ajustement de (b). Énoncez ensuite —

sans démonstration — le théorème de complétude du *do*-calcul (Shpitser-Pearl et Huang-Valtorta, 2006) : dès qu’une loi interventionnelle est identifiable à partir du graphe et de la loi observationnelle, le *do*-calcul permet de la dériver.

- (d) *Lisez la frontière et rendez-en compte honnêtement : l’analyse de sensibilité (quelle doit être la force d’un facteur de confusion non mesuré pour renverser une conclusion ?), l’interférence entre unités (le traitement d’une unité affecte le résultat d’une autre, de sorte que la notation en résultats potentiels ci-dessus est déjà fausse), et l’estimation de τ lorsque les fonctions de nuisance sont ajustées par apprentissage automatique (apprentissage automatique double/débiaisé). Pour chacun, dites précisément quelles parties sont des théorèmes et lesquelles sont ouvertes. État des lieux : (a)–(c) sont des mathématiques établies datant de 1974–2006 ; les trois sujets de (d) sont des domaines de recherche actifs, avec des résultats partiels et aucune théorie générale établie.*

Jerzy Neyman écrivit les résultats potentiels pour des expériences agricoles en 1923 ; Donald Rubin les fit revivre et les généralisa à partir de 1974, et Judea Pearl construisit le pendant graphique, ce qui lui valut le prix Turing en 2011. Les deux écoles se sont disputées pendant des décennies et sont aujourd’hui comprises comme des formalismes équivalents pour un même contenu. Ce qui en fait un problème de recherche plutôt qu’un exercice de manuel, c’est que les hypothèses qui font tout le travail — pas de confusion non mesurée, pas d’interférence — ne sont pas testables à partir des données, de sorte que la mathématique de l’inférence causale est largement la mathématique de l’énoncé exact de ce que l’on doit supposer, et de la mesure du tort que l’on subit si l’on se trompe.

Références :

- Contexte : Modèle causal de Neyman-Rubin — Wikipédia (https://fr.wikipedia.org/wiki/Mod%C3%A8le_causal_de_Neyman-Rubin)
- Contexte : Inférence causale — Wikipédia (https://fr.wikipedia.org/wiki/Inf%C3%A9rence_causale)
- Article : P. R. Rosenbaum & D. B. Rubin, « The central role of the propensity score in observational studies for causal effects », *Biometrika* 70 (1983), 41–55
- Lecture : J. Pearl, *Causality*, 2e éd. (2009) ; G. Imbens & D. Rubin, *Causal Inference for Statistics, Social, and Biomedical Sciences* (2015)

Problème 39 (Quand interpoler le bruit est sans danger — Recherche, short). **STA-39. Problème.** *En régression linéaire avec plus de prédicteurs que d’observations, la solution des moindres carrés de norme ℓ_2 minimale ajuste exactement les données d’apprentissage — tous les résidus nuls, bruit compris — et la théorie classique (STA-26) prédit le désastre, alors qu’en pratique de tels estimateurs prédisent souvent bien. Rédigez un compte rendu précis de l’état des lieux : énoncez la caractérisation de Bartlett, Long, Lugosi et Tsigler (2020) des situations où l’interpolation est bénigne, en termes de rangs effectifs du spectre de la covariance, énoncez exactement ce que la courbe de double descente de Belkin, Hsu, Ma et Mandal (2019) démontre et ce qu’elle ne démontre pas, et dites honnêtement quelles parties du tableau sont des théorèmes sur les modèles linéaires et à noyau et lesquelles restent conjecturales pour les réseaux profonds.*

Pendant cinquante ans, la courbe en U de STA-26 a été enseignée comme une loi : au-delà d’une certaine souplesse, l’erreur de test doit remonter. Vers 2018, les praticiens n’ont cessé d’exhiber des modèles ayant plus de paramètres que de points de données, qui interpolaient l’ensemble d’apprentissage et généralisaient quand même, et la théorie a dû être reconstruite plutôt que défendue. Pour la régression linéaire de norme minimale, la réponse est aujourd’hui essentiellement complète et quantitative — le surajustement bénin se produit exactement lorsque le spectre de la covariance possède beaucoup de directions petites pour absorber le bruit tandis que quelques grandes portent

le signal — et des résultats analogues existent pour la régression à noyau sans crête. État en 2026 : réglé pour la régression linéaire et à noyau de norme minimale sous des conditions spectrales explicites ; pour les réseaux profonds entraînés par descente de gradient, le phénomène est documenté empiriquement et expliqué seulement dans des régimes restreints.

Références :

- Contexte : Double descente — Wikipédia (en anglais) (https://en.wikipedia.org/wiki/Double_descent)
- Article : P. L. Bartlett, P. M. Long, G. Lugosi & A. Tsigler, « Benign overfitting in linear regression », *PNAS* 117 (2020), 30063–30070, arXiv :1906.11300 (<https://arxiv.org/abs/1906.11300>)
- Article : M. Belkin, D. Hsu, S. Ma & S. Mandal, « Reconciling modern machine-learning practice and the classical bias–variance trade-off », *PNAS* 116 (2019), 15849–15854

Problème 40 (Une inférence qui ne révèle rien sur personne — Recherche). **STA-40. Problème.**

Un algorithme randomisé M est ε -différentiellement confidentiel si pour tout couple de jeux de données D, D' différant par l'enregistrement d'un seul individu et tout ensemble mesurable S ,

$$P(M(D) \in S) \leq e^\varepsilon P(M(D') \in S).$$

La question de ce problème est de savoir ce qu'une telle contrainte coûte en précision statistique.

- (a) Démontrez la boîte à outils de base. Pour une statistique f de sensibilité globale $\Delta f = \max_{D \sim D'} |f(D) - f(D')|$, démontrez que publier $f(D) + \text{Laplace}(\Delta f / \varepsilon)$ est ε -différentiellement confidentiel ; démontrez que toute fonction d'une sortie confidentielle est confidentielle avec le même ε (post-traitement) ; et démontrez qu'exécuter des mécanismes de paramètres $\varepsilon_1, \dots, \varepsilon_k$ sur les mêmes données est $(\varepsilon_1 + \dots + \varepsilon_k)$ -confidentiel.
- (b) Chiffrez la garantie dans le modèle central, où un dépositaire de confiance détient les données. Pour la moyenne de n nombres de $[0, 1]$, calculez la sensibilité, et démontrez que l'écart type du bruit de confidentialité est d'ordre $1/(n\varepsilon)$ tandis que l'écart type d'échantillonnage est d'ordre $1/\sqrt{n}$. Concluez précisément pour quelles suites $\varepsilon = \varepsilon_n$ le bruit de confidentialité est asymptotiquement négligeable.
- (c) Chiffrez-la dans le modèle local, où chaque individu randomise avant de publier quoi que ce soit. Montrez que la réponse randomisée de Warner (1965) — répondre sincèrement avec probabilité p , sinon inverser la réponse — est ε -confidentielle avec $\varepsilon = \log \frac{p}{1-p}$, construisez l'estimateur sans biais de la proportion dans la population, et démontrez que sa variance est gonflée d'un facteur d'ordre $1/\varepsilon^2$ pour ε petit. Énoncez ensuite le théorème minimax de Duchi, Jordan et Wainwright : sous confidentialité locale, la taille d'échantillon effective est d'ordre $n\varepsilon^2$ plutôt que n , et aucune procédure n'y échappe.
- (d) Rendez compte de la frontière en séparant les théorèmes des problèmes ouverts. Considérez (i) les intervalles de confiance et les tests d'hypothèse à validité exacte en échantillon fini sous confidentialité, (ii) le choix de ε , qui est une décision politique sans aucune théorie statistique pour la guider — le Bureau du recensement des États-Unis a dû en fixer un pour le recensement de 2020 et s'est fait attaquer en justice pour les conséquences — et (iii) la confidentialité pour des données dont les enregistrements sont dépendants, comme dans les réseaux ou en cas de participation répétée, où la définition même d'un « jeu de données voisin » est contestée. Pour chacun, dites ce qui est démontré et ce qui ne l'est pas. État des lieux : les mécanismes de (a) et les vitesses minimax de (b)–(c) sont des mathématiques établies ; l'inférence confidentielle, la sémantique du budget de confidentialité sur la durée de vie d'un jeu de données et la confidentialité sous dépendance sont des recherches ouvertes et actives.

La confidentialité différentielle a été définie par Cynthia Dwork, Frank McSherry, Kobbi Nissim et Adam Smith en 2006 pour sortir d'un piège : toute notion antérieure d'anonymisation avait été brisée par des attaques de réidentification, et le domaine avait besoin d'une garantie ne dépendant pas de ce qu'un attaquant savait déjà. La définition offre exactement cela — une borne sur le déplacement que la participation d'une seule personne peut imprimer à la loi de la sortie — et elle a été déployée par Apple, par Google et, de la façon la plus lourde de conséquences, par le recensement américain de 2020. Ce déploiement est le lieu où statistique et politique publique sont entrées en collision : les démographes objectaient que des effectifs bruités à petite échelle déforment précisément les populations que le recensement existe pour compter, tandis que le Bureau soutenait que les attaques par reconstruction sur les données de 2010 avaient déjà rendu illusoires les anciennes protections. La mathématique de l'arbitrage — combien de précision une promesse de confidentialité doit coûter — est l'un des domaines les plus actifs de la statistique théorique.

Références :

- Contexte : Confidentialité différentielle — Wikipédia (https://fr.wikipedia.org/wiki/Confidentialit%C3%A9_diff%C3%A9rentielle)
- Article : S. L. Warner, « Randomized response : a survey technique for eliminating evasive answer bias », *Journal of the American Statistical Association* 60 (1965), 63–69
- Article : J. C. Duchi, M. I. Jordan & M. J. Wainwright, « Minimax optimal procedures for locally private estimation » (2016–17), arXiv :1604.02390 (<https://arxiv.org/abs/1604.02390>)
- Lecture : C. Dwork & A. Roth, *The Algorithmic Foundations of Differential Privacy* (2014)

Pour aller plus loin

Hors de la Caverne — des problèmes, pas de réponses.